

IMPACTO DE EVENTOS EXÓGENOS SOBRE O MERCADO FINANCEIRO

2020020345 - Chaquel Nataly Alcino

2025007936 - Eduardo Antônio dos Santos Silva

2024009210 - Lucas Arouca Baldoni Mello Palhares

2022004879 - Luiz Gustavo Gonçalves Rodrigues

2024016073 - Thiago Luiz de Matos

CMAC03 – Algoritmos em Grafos

Prof. Rafael Frinhani



INSTITUTO DE
MATEMÁTICA E
COMPUTAÇÃO

UNIFEI - Itajubá



Impacto de Eventos Exógenos sobre o Mercado Financeiro

1 Introdução

Os mercados financeiros são ambientes altamente dinâmicos, nos quais preços, volumes negociados e níveis de volatilidade refletem continuamente as expectativas dos agentes econômicos diante das informações disponíveis. Segundo a Hipótese dos Mercados Eficientes, os preços dos ativos tendem a incorporar as informações relevantes disponíveis ao mercado, o que torna notícias, anúncios econômicos, decisões políticas e eventos inesperados fatores capazes de influenciar rapidamente o comportamento dos investidores (Fama, 1970). Dessa forma, o mercado financeiro não pode ser compreendido apenas como uma sequência isolada de preços históricos, mas como um sistema de comportamento estocástico sensível à chegada de novas informações e à forma como essas informações são interpretadas pelos participantes do mercado.

Os eventos exógenos influenciam o comportamento incerto e dinâmico dos sistemas financeiros. Estes acontecimentos são externos ao funcionamento regular do mercado e produzem impactos significativos sobre ele. Os eventos podem ter natureza política, econômica, ambiental, social ou geopolítica, tais como conflitos internacionais, discursos de líderes políticos, decisões de bancos centrais, anúncios de políticas monetárias, desastres climáticos, acidentes ambientais e crises institucionais. Pode-se afirmar que os acontecimentos exógenos podem gerar reações em cadeia no mercado de ativos, refletidas em variações de preços, volumes negociados e volatilidade de diferentes classes de títulos financeiros (Mantegna & Stanley, 2000).

A análise desses impactos é relevante porque a reação do mercado a um evento externo nem sempre ocorre de forma simples, direta ou imediata. Um conflito geopolítico, por exemplo, pode afastar inicialmente ativos ligados a energia, commodities ou defesa, mas seus efeitos podem se propagar para índices de mercado, moedas, empresas de transporte, cadeias produtivas e setores indiretamente relacionados. Da mesma forma, uma decisão de política monetária pode impactar ações, fundos imobiliários, câmbio e títulos financeiros em diferentes intensidades e intervalos de tempo. Assim, o desafio não está apenas em observar se um ativo variou após determinado evento, mas em compreender quais ativos reagiram, qual foi a intensidade dessa reação, por quanto tempo ela persistiu e se houve efeitos indiretos ou encadeados entre ativos.

Nesse contexto, a metodologia de Estudo de Eventos se apresenta como uma base importante para investigar a relação entre acontecimentos exógenos e o comportamento dos preços dos ativos. Segundo MacKinlay, estudos de eventos são utilizados para medir o efeito de um evento econômico sobre o valor de uma empresa ou ativo, observando o comportamento dos retornos em uma janela temporal próxima ao aconteci-

mento analisado (MacKinlay, 1997). Essa abordagem permite comparar o retorno observado com um retorno esperado, à medida que evidencia possíveis retornos anormais associados ao evento. Na investigação que propomos, tal perspectiva é especialmente relevante, pois contribui para diferenciar movimentos comuns do mercado de variações potencialmente associadas e derivadas de choques externos.

Entretanto, analisar apenas ativos de forma individual pode limitar a compreensão do problema, uma vez que o mercado financeiro é formado por relações de dependência, correlação e influência entre diferentes ativos. Por isso, a Teoria dos Grafos surge como uma ferramenta adequada para representar esse sistema de maneira estrutural. Em uma modelagem baseada em grafos, eventos e ativos podem ser representados como vértices, enquanto relações de impacto, correlação ou propagação podem ser representadas por arestas ponderadas. Essa estrutura permite visualizar e analisar conexões que não seriam facilmente percebidas por meio de análises isoladas de séries temporais.

As propostas conceituais e metodológicas das áreas de Econofísica e Ciência das Redes são relevantes para a análise de mercados financeiros. Mantegna analisou a estrutura hierárquica de mercados financeiros a partir de correlações entre ativos, por meio de representações em rede para identificar influências mútuas e relevantes entre ações (Mantegna, 1999). Conforme demonstrado pelo autor, grafos podem ser utilizados para reduzir a complexidade de grandes conjuntos de ativos, evidenciar agrupamentos, identificar conexões centrais e compreender melhor a organização interna do mercado. Propomos que esta abordagem seja ampliada a partir da integração de eventos exógenos como elementos centrais da rede. Assim, possibilita-se a análise da estrutura interna do mercado e, sobretudo, a dinâmica de efeitos em cadeia dos choques externos se conectam a essa estrutura.

A investigação do mercado de capitais pressupõe relações entre títulos e eventos que se modificam ao longo do tempo. O impacto de uma notícia ou desastre climático (evento exógeno), por exemplo, está relacionado a um intervalo de tempo específico, na qual podem ser notados efeitos imediatos, defasados, contínuos ou temporários sobre os ativos financeiros. Nesse sentido, o caráter temporal e variável dos efeitos que atingem os ativos pode ser apreendido e modelado por meio de Redes Temporais. Este método permite que sejam representados sistemas complexos de conexões de caráter volátil: surgem, desaparecem ou se alteram conforme a dinâmica intrínseca ao fenômeno analisado (Holme & Saramäki, 2012).

Estabelecemos como recorte contextual de análise a observação do início do conflito militar entre Rússia e Ucrânia, em fevereiro de 2022. Neste evento, foi observado um impacto significativo na rede global de ativos financeiros (Zaheer et al.,

2024). Trata-se de um evento geopolítico que afetou de forma simultânea e assimétrica múltiplos setores do sistema de negociação de ativos. Já o recorte temporal adotado é o intervalo de 21 de fevereiro a 24 de março de 2022. Esta delimitação corresponde às quatro semanas iniciais do conflito. Neste período, pode-se observar, de maneira privilegiada, a incerteza diante da eclosão da guerra e do primeiro pacote de sanções econômicas bilaterais.

Em relação aos títulos financeiros investigados, definimos o recorte de 7 ativos que correspondem, individualmente, a um segmento macroeconômico. O Petróleo Brent (BZ=F) exemplifica os choques nos setores de energia; a Lockheed Martin (LMT) representa as expectativas de reconfiguração de orçamentos de defesa militar do Ocidente; o Trigo (ZW=F) reflete a insegurança do fornecimento de grãos na bacia do Mar Negro; a CrowdStrike (CRWD) evidencia a possibilidade de ocorrência de uma ciberguerra; o Ouro (GC=F) atua como o refúgio clássico de liquidez em momentos de incerteza; o Rublo Russo (RUB=X) expressa a dinâmica cambial da Rússia sob sanções financeiras severas; e a Petrobras (PETR4.SA) representa um exportador de commodities neutro, que pode ter sido uma alternativa atrativa para investidores que deixavam os mercados do leste europeu.

As fontes que embasaram a investigação são provenientes das bases de dados do GDELT (Global Database of Events, Language, and Tone) e do Yahoo! Finance (via API yfinance). O yfinance permite a extração das cotações de mercado e seus respectivos preços diários de fechamento. Já nossa fonte de eventos exógenos foi constituída pelo GDELT, um repositório global de monitoramento midiático que utiliza a taxonomia CAMEO (Conflict and Mediation Event Observations) para classificar, datar e quantificar a intensidade das ações geopolíticas de forma padronizada (Schrodt & Gerner, 2001).

Portanto, o objetivo desta investigação é propor uma abordagem computacional baseada em redes temporais para representar, integrar e analisar dados de eventos geopolíticos e séries financeiras, de forma a observar as correlações estruturais e causais identificadas neste conjunto de informações. A partir dessa solução, buscamos evidenciar padrões relevantes de efeitos em cadeia, originados a partir de choques externos que se propagam no mercado financeiro.

2 Referencial Teórico

Como pressuposto para nossa análise, consideramos as proposições da Hipótese de Eficiência de Mercado (HEM), em seu modelo semiforte. A HEM é um dos pilares da Moderna Teoria de Finanças. Segundo Fama, esta hipótese define que os preços dos ativos do mercado financeiro incorporam, de forma racional e rápida, as informações consideradas relevantes e que são disponíveis ao mercado (Fama, 1970). Nesse sentido, diante de um novo dado significativo, os agentes econômicos ajustam suas expectativas e, por conseguinte, os valores dos ativos são reavaliados.

Também consideramos a metodologia do Estudo de Eventos (*Event Study*). De acordo com Camargos e Barbosa (Camargos & Barbosa, 2003), o estudo de eventos consiste em uma metodologia voltada para analisar o efeito de informações relevantes sobre os preços das ações. Sua metodologia permite avaliar se a dinâmica de desempenho dos preços de títulos em

dias próximos ao acontecimento tem sido anormal, expresso em retornos esperados atípicos.

A aplicação do Estudo de Eventos consiste na delimitação de uma janela de estimação em um período anterior ao da janela de evento, com a finalidade de calcular os retornos normais. Em nossa análise, estabelecemos que os eventos exógenos serão nossa data de referência ($T=0$). A janela de estimação deve ser longa o suficiente para diluir possíveis discrepâncias nos preços das ações e evitar alterações bruscas na distribuição de frequência (Camargos & Barbosa, 2003). A Janela de Estimação e a Janela do Evento não podem se sobrepor (MacKinlay, 1997). Caso isso ocorra, o próprio impacto do evento passaria a integrar o cálculo do retorno “normal” do ativo, comprometendo a capacidade do modelo de isolar a anomalia que se pretende medir.




Figura 1: Linha de Tempo de um Estudo de Evento. Fonte: Camargos & Barbosa (2003)

Em que:

- $t = 0$ é a data do evento
- $t = T_0 + 1$ até $t = T_1$ é a janela de estimação e $L_1 = T_1 - T_0$, a sua extensão
- $t = T_1 + 1$ até $t = T_2$ é a janela de evento e $L_2 = T_2 - T_1$, a sua extensão
- $t = T_2 + 1$ até $t = T_3$ é a janela de comparação e $L_3 = T_3 - T_2$, a sua extensão

2.1 Modelos de Retorno Anormal

O Retorno Anormal (AR_{it}) corresponde à diferença entre o retorno observado do ativo i na data t e o retorno esperado segundo um modelo de precificação, caso o evento não tivesse ocorrido:

$$AR_{it} = R_{it} - E(R_{it} | X_t) \quad (1)$$

Existem três abordagens principais para estimar esse retorno esperado:

1. **Retorno Ajustado à Média Constante:** considera o retorno esperado constante e igual à média histórica do ativo. É a abordagem mais simples, mas ignora as oscilações gerais do mercado.
2. **Retorno Ajustado ao Mercado:** iguala o retorno esperado de qualquer ativo ao retorno de um portfólio de mercado amplo (como o Ibovespa), removendo a variação sistêmica da bolsa, mas sem considerar o risco específico de cada ativo.

3. **Modelo de Mercado (*Market Model*):** estima uma relação linear entre o retorno do ativo e o retorno do portfólio de mercado por meio de regressão por Mínimos Quadrados Ordinários (MQO).

Soares, Rostagno & Soares (2002) e Campbell, Lo & MacKinlay (MacKinlay, 1997) apontam o Modelo de Mercado como o mais eficaz na detecção de anomalias, já que ele isola a parcela do retorno associada à variação geral do mercado e incorpora o coeficiente de risco sistemático β_i de cada ativo reduzindo a variância do retorno anormal e aumentando o poder estatístico dos testes. Por esse motivo, ele é o modelo adotado neste trabalho para o cálculo do retorno anormal.

Para acumular esse efeito ao longo da janela do evento, utiliza-se o **Retorno Anormal Acumulado (CAR)**:

$$CAR_i(t_1, t_2) = \sum_{t=t_1}^{t_2} AR_{it} \quad (2)$$

2.2 Teoria dos Grafos e Redes Temporais Multicamadas

O Estudo de Eventos isola o impacto de um acontecimento sobre um ativo individual, mas o mercado financeiro não funciona como uma coleção de ativos independentes: existem relações de correlação e dependência entre eles que uma análise isolada não captura. A Teoria dos Grafos oferece uma forma de representar esse sistema de maneira estrutural, modelando eventos e ativos como vértices e suas relações de impacto, correlação ou propagação como arestas ponderadas.

Mantegna utilizou essa abordagem ao estudar a estrutura hierárquica de mercados financeiros, aplicando o algoritmo da **Árvore Geradora Mínima (*Minimum Spanning Tree*)** sobre uma matriz de correlações para extrair apenas as conexões mais relevantes entre os ativos reduzindo uma rede densa a um “esqueleto” que evidencia os agrupamentos e conexões centrais do mercado (Mantegna, 1999). A técnica converte o Coeficiente de Correlação de Pearson entre pares de ativos em uma medida de distância ultramétrica, o que permite extrair essa topologia de forma sistemática.

Há ainda outro aspecto a considerar: as relações entre eventos e ativos não são estáticas, e sim mudam ao longo do tempo, surgindo e desaparecendo conforme a dinâmica do mercado. Redes temporais foram propostas justamente para representar esse tipo de sistema, no qual as conexões variam em janelas de tempo discretas (Holme & Saramäki, 2012) característica importante no caso de eventos exógenos, cujo impacto tende a se concentrar em uma janela específica e pode produzir efeitos imediatos, defasados ou apenas temporários.

O problema tratado neste trabalho combina, na verdade, duas dinâmicas de natureza distinta: o choque exógeno, que é direcionado e bipartido (evento $\rightarrow$ ativo), e a correlação entre ativos, que é não direcionada e interna ao mercado. Para representar essas duas dinâmicas sem misturá-las, adota-se uma modelagem em **rede multicamadas (*multiplex*)**, na qual os mesmos vértices participam de camadas distintas de relação (Holme & Saramäki, 2012). Essa separação é o que permite, simultaneamente, isolar o efeito causal de um evento específico e capturar o comportamento sistêmico do mercado.

3 Solução proposta

Esta seção apresenta o artefato computacional desenvolvido para suportar a análise de risco e a formulação de estratégias de investimento, utilizando métodos científicos de coleta, integração e análise de dados.

A avaliação contínua e a validação de modelos como o aqui proposto são ferramentas vitais, pois auxiliam na compreensão de como a informação se propaga no mercado, permitindo o aprimoramento da resiliência de portfólios frente a eventos adversos.

3.1 Detalhamento do problema

Diante do desafio de investigar como o mercado financeiro global reage a eventos exógenos, tais como conflitos geopolíticos, desastres climáticos extremos ou anúncios de políticas macroeconômicas, a solução adotada concentra-se na **Modelagem de Grafos Temporais Multiplex (Multicamadas)** (Kivelä et al., 2014), cujo embasamento teórico é apresentado na Seção 2.2. A eficácia e a precisão desta abordagem dependem diretamente da diversidade, do grau de detalhamento e da atualização contínua das informações processadas a partir dos dados do **GDELT** e **yfinance**.

Neste contexto, a modelagem formal em grafos foi concebida com os seguintes propósitos:

- **Organizar a complexidade:** Transformar um volume massivo e heterogêneo de dados (um fluxo global de notícias e o histórico de negociação de dezenas de ativos) em uma rede estruturada, onde relações de causa e efeito tornam-se explícitas e testáveis por meio do isolamento de retornos anormais, fundamentado na metodologia de **Estudo de Eventos** (Seção 2).
- **Gerar insights estratégicos:** Capturar padrões estruturais de contágio e relações de dependência temporal entre choques no mundo real (Eventos) e o comportamento dos mercados (Ativos) ao longo dos pregões (dias úteis de negociação). Essa captura de padrões revela cascatas de reações e correlações indiretas que dificilmente seriam identificadas ou mapeadas utilizando apenas ferramentas tradicionais de análise isolada de séries temporais.

3.2 Características do Dataset

Conforme delimitado na Introdução (Seção 1), o recorte analisado neste trabalho restringe-se ao período de 21 de fevereiro a 24 de março de 2022, equivalente a aproximadamente 24 pregões, e a um conjunto fixo de 7 ativos financeiros. Essa delimitação reduz substancialmente o volume de dados em relação ao histórico completo disponível nas duas fontes, o que impõe características específicas à coleta e ao pré-processamento.

3.2.1 GDELT

O **GDELT (*Global Database of Events, Language, and Tone*)** (Leetaru & Schrodt, 2013) é atualizado a cada 15 minutos e classifica os eventos extraídos de notícias globais segundo a taxonomia **CAMEO** (Schrodt & Gerner, 2001), que organiza mais de 300 categorias de eventos em quatro classes (cooperação verbal, cooperação material, conflito verbal e conflito

material). Para este trabalho, o universo de eventos foi restringido àqueles ocorridos dentro da janela escolhida e relacionados ao conflito identificados por meio dos campos de ator (Actor1CountryCode/Actor2CountryCode referentes a Rússia e Ucrânia) e das categorias CAMEO associadas a conflito material. Os campos utilizados são:

- GlobalEventID: identificador único do evento, índice do vértice em V_E ;
- SQLDATE: data do evento, usada para associá-lo ao pregão correspondente;
- EventCode (CAMEO): categoria do evento;
- GoldsteinScale: ferramenta quantitativa para medir o nível de conflito ou cooperação na interação entre países ou grupos;
- NumMentions / NumSources: volume de cobertura midiática, utilizável como filtro de relevância.

Por se tratar de uma janela curta (quatro semanas) e de um único evento geopolítico, o volume de registros disponível é necessariamente menor do que em estudos que exploram o histórico completo do GDELT (desde 1979). Some-se a isso o viés de cobertura típico da base (eventos amplamente noticiados em veículos ocidentais e de língua inglesa tendem a ser sobre-representados) e a alta probabilidade de registros duplicados, que ocorre quando múltiplos veículos noticiam o mesmo acontecimento de formas distintas.

3.2.2 yfinance

Os 7 ativos selecionados (Seção 1) cobrem classes distintas de instrumentos financeiros, refletidas na própria notação de *ticker* do yfinance: ações negociadas na bolsa americana (LMT, CRWD), uma ação negociada na B3 (PETR4.SA), contratos futuros de commodities (BZ=F, ZW=F, GC=F) e um par cambial (RUB=X). Essa heterogeneidade implica calendários de negociação distintos entre os ativos, bolsas de valores, mercados futuros e o mercado cambial operam em horários e feriados próprios, o que é considerado na regra de aglomeração temporal.

Apenas o **preço diário de fechamento** (Close) de cada ativo é utilizado, dado que o modelo opera em granularidade de pregão. Vale notar que, embora a Janela do Evento analisada cubra apenas as quatro semanas do recorte, a estimação do retorno esperado $E[R_{v,t}]$ pelo Modelo de Mercado exige uma **Janela de Estimação** anterior a 21/02/2022, viabilizada pelo fato de o yfinance manter profundidade histórica de dados diários de vários anos para todos os 7 ativos selecionados, sem as restrições de 60 ou 7 dias que se aplicam apenas a granularidades intradiárias.

Por fim, cabe registrar que o recorte de 7 ativos e 24 pregões é deliberadamente reduzido em relação ao tamanho potencial do dataset, uma escolha que viabiliza a análise qualitativa e ilustrativa do modelo proposto, mas que limita a representatividade estatística dos resultados frente ao mercado financeiro como um todo.

3.3 Modelagem

Para representar a complexa dinâmica de contágio de informações, propõe-se a modelagem de um **Grafo Temporal Multiplex**, denotado formalmente como $G = (V, E, T)$. A motivação teórica para a escolha de uma rede multicamadas, capaz de modelar simultaneamente o choque exógeno (bipartido e direcionado) e a correlação entre ativos (não direcionada), é discutida em detalhe na Seção 2.2.

3.3.1 Avaliação de Alternativas de Modelagem

Como rigor metodológico, outras duas abordagens foram descartadas em favor da Rede Multiplex:

1. **Grafo Estático de Correlação Global:** Abordagens baseadas exclusivamente em matrizes de correlação estática (Tumminello et al., 2010) agregam toda a janela de observação em um único grafo, o que destrói a causalidade. Um evento geopolítico é um choque pontual. Uma correlação de longo prazo “dilui” a anomalia nos dias de normalidade.
2. **Grafo Homogêneo de Contágio Financeiro Simples:** Modelos de conectividade sistêmica baseados apenas em retornos financeiros (Billio et al., 2012) tratam o mundo real como um sistema em que apenas as relações entre entradas e saídas são modeladas, sem explicitar os mecanismos internos. Sem os Eventos como vértices (V_E), impossibilita-se a identificação automatizada (via métricas de centralidade) de quais tipos de notícias balançam o mercado.

3.3.2 Vértices e arestas

Para a modelagem, foi definido que o conjunto de vértices V é definido pela união disjunta $V = V_E \cup V_A$, onde:

- V_E : Conjunto de vértices representando os **Eventos Exógenos**, cujos dados são extraídos do banco de dados GDELT (Leetaru & Schrod, 2013).
- V_A : Conjunto de vértices representando os **Ativos Financeiros**, extraídos da API yfinance.

Analogamente, o conjunto de arestas é particionado em $E = E_{ex} \cup E_{in}$, representando a camada exógena e a camada intra-mercado, respectivamente.

3.3.3 Dinâmica Temporal

A dimensão temporal T do grafo é discretizada em janelas de tempo (*snapshots*) que correspondem estritamente aos **pregões** da bolsa de valores. Como o fluxo de informações no mundo real é ininterrupto e o mercado financeiro opera em janelas fechadas, adotou-se uma regra de aglomeração: eventos capturados pelo GDELT que ocorrem durante finais de semana ou fora do horário comercial são acumulados no vértice temporal correspondente ao pregão imediatamente subsequente. Essa discretização temporal é crucial para capturar o “efeito de segunda-feira” (French, 1980) ou *gaps* de abertura, preservando a cronologia causal.

3.3.4 Camada Exógena (E_{ex}): Condição de Anomalia e Retorno Anormal

Diferente de redes estáticas densas, propõe-se um mecanismo de filtragem baseado na metodologia de Estudo de Eventos (Seção 2). Uma aresta direcionada $e_{ex}(u, v, t)$ do evento $u \in V_E$ para o ativo $v \in V_A$ na janela do evento (Seção 2, Figura 2) só é estabelecida se o ativo v apresentar, segundo o Retorno Anormal $AR_{v,t}$ (Eq. 1) estimado via Modelo de Mercado, um comportamento anômalo *ex-post*:

$$E_{ex} = \{(u, v, t) \mid u \in V_E, v \in V_A, |AR_{v,t}| \geq x\} \quad (3)$$

Em que x é o limiar de sensibilidade predefinido que indica significância estatística.

Para as arestas válidas, o peso deve refletir a magnitude conjunta do choque exógeno. Adota-se o Retorno Anormal Acumulado $CAR_v(t_1, t_2)$ (Eq. 2) multiplicado pela **Escala Goldstein** (Goldstein, 1992), fornecida pelo GDEL. Por exemplo, um forte ataque hacker (e_2 , Figura 2) afeta substancialmente empresas de segurança ($w = 0,48$), enquanto um conflito distante (e_1 , Figura 2) gera um choque no Mercado Brasileiro ($w = 0,06$):

$$w_{u \rightarrow v}(t) = |Goldstein_{u,t}| \times |CAR_v(t_1, t_2)| \quad (4)$$

3.3.5 Camada Intra-Mercado (E_{in}): Correlação de Pearson e Cascatas

Embora a modelagem bipartida capture o choque direto, a compreensão sistêmica do risco exige a análise do movimento entre os ativos ($V_A \leftrightarrow V_A$). Propõe-se uma camada de conexões não-direcionadas cujos pesos fundamentam-se no Coeficiente de Correlação de Pearson (Pearson, 1895) ($\rho_{i,j}$), aplicado aos retornos de cada par de ativos.

Para extrair a topologia relevante dessa rede nativamente densa (ilustrada pelas arestas genéricas com $w = 1$ na representação didática da Figura 2), aplica-se o algoritmo da Árvore Geradora Mínima sobre a distância, definida por:

$$d_{i,j} = \sqrt{2(1 - \rho_{i,j})} \quad (5)$$

O resultado é a ultramétrica subdominante associada ao grafo, que representa o "esqueleto" do mercado financeiro, evidenciando como choques exógenos podem se propagar entre ativos e desencadear efeitos em cascata.




Figura 2: Amostra ilustrativa de um snapshot de um grafo multiplex contendo 2 eventos diferentes da guerra entre Rússia x Ucrânia (e_1 , e_2) e 4 ativos (Mercado Brasileiro, Energia, Cybersec e Defesa). As arestas direcionadas refletem o choque exógeno (com pesos $w = 0,06$ e $w = 0,48$), enquanto as arestas intra-mercado ($w = 1$) ilustram a teia de correlação endógena do ecossistema financeiro.

3.3.6 Consistência entre Modelo e Solução

A estrutura garante alinhamento direto com o núcleo computacional. O grafo multicamadas (esparso na camada exógena via CAR, e filtrado na camada intra-mercado via MST) permite que os algoritmos de busca operem com alta precisão e sem ruído estatístico.

3.4 Desenvolvimento

A partir da modelagem formal apresentada na Seção 3.3, o protótipo foi implementado em Python 3. Cada etapa do processo reside em um módulo independente e testável de forma isolada. A Tabela 1 resume a organização.

Tabela 1: Módulos do protótipo e suas responsabilidades.

Módulo	Responsabilidade
fonte_gdelt.py	Eventos exógenos
fonte_yfinance.py	Preços dos ativos
grafo_base.py	Grafos de correlação
algo_mst.py	Árvore Geradora Mínima
algo_louvain.py	Detecção de comunidades
algo_dijkstra.py	Caminhos de contágio
experimentos.py	Estudo de eventos
visualizacao.py	Geração de todas as figuras
main.py	Roda todos os módulos

3.4.1 Ingestão e pré-processamento dos dados

Os preços de fechamento ajustado dos ativos são obtidos via API yfinance. Para cada ativo, a série de preços P_t é convertida em **retornos logarítmicos**. $R_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$. A Equação (3.4.1) é essencial para o cálculo do Retorno Anormal Acumulado (CAR), pois permite somar diretamente os retornos di-

ários ao longo da janela do evento. Em conformidade com o **Modelo de Retorno Médio Constante** adotado (Seção 2).

3.4.2 Construção das camadas do grafo

A camada intra-mercado (E_{in}) é instanciada a partir da matriz de correlação de Pearson (Seção 3.3). Para os algoritmos que exigem uma métrica de distância, a correlação é convertida na distância de Mantegna (Eq. 5), de modo que correlações fortes ($\rho \rightarrow 1$) correspondem a distâncias curtas ($d \rightarrow 0$). Já o algoritmo de Louvain opera sobre o grafo de **similaridade**, cujo peso é $|\rho_{i,j}|$ e cuja aresta só existe se $|\rho_{i,j}| \geq \text{LIMIAR_CORRELACAO}$. Dada a natureza diversificada do conjunto, adotou-se $\text{LIMIAR_CORRELACAO} = 0,10$, compatível com os níveis de correlação observados entre estes ativos (Seção 4).

A camada exógena (E_{ex}) é construída como um **grafo direcionado evento→ativo**: para cada par (evento, ativo) executa-se o estudo de eventos e cria-se uma aresta dirigida sempre que o retorno anormal padronizado satisfaz $|z_{AR}| \geq 2$ (Seção 3.4.4). Cada aresta recebe o peso $w_{u \rightarrow v} = |\text{Goldstein}_u| \times |\text{CAR}_v|$ (Eq. 4), combinando a relevância geopolítica do evento e a magnitude.

3.4.3 Núcleo algorítmico

Três algoritmos foram implementados sobre a biblioteca `networkx`, cada um visando entender da estrutura do mercado.

Árvore Geradora Mínima (MST). Aplicada sobre o grafo de distância de Mantegna, obtém o *esqueleto* do mercado: as $|V_A| - 1$ ligações de maior correlação que conectam todos os ativos. O grau de cada vértice na árvore identifica os ativos centrais (*hubs*). A complexidade é $O(E \log E)$.

Detecção de comunidades (Louvain). Particiona a rede de similaridade maximizando a modularidade Q , agrupando ativos que se movem em conjunto, e busca verificar em que medida as comunidades emergentes correspondem aos setores (Seção 4, métrica de pureza). A complexidade empírica é aproximadamente $O(n \log n)$.

Caminhos de contágio (Dijkstra). Dado o ativo de entrada do choque de um evento, definido como aquele de maior $|\text{CAR}|$ na janela, o algoritmo computa os caminhos de menor distância acumulada até os demais ativos, traçando a propagação do choque pela rede.

3.4.4 Validação por Estudo de Eventos

A presença de uma aresta $e_{ex}(u, v, t)$ é validada estatisticamente pelo Modelo de Retorno Médio Constante. Sobre uma **janela de estimação de 60 pregões**, separada do dia do choque por um **período de carência de 10 dias** (que impede que rumores pré evento impactem o comportamento normal), estimam-se a média histórica μ_i e a volatilidade σ_i de cada ativo. O retorno anormal é o resíduo $AR_{i,t} = R_{i,t} - \mu_i$, e seu acúmulo na janela do evento (CAR) é padronizado:

$$z_{AR} = \frac{\text{CAR}_v(t_1, t_2)}{\sigma_i \sqrt{n}}, \quad (6)$$

onde σ_i é a volatilidade histórica do próprio ativo e n o número de pregões da janela. Adota-se o limiar $|z_{AR}| \geq 2$ como critério de anomalia (significância de aproximadamente 5% sob normalidade); para a janela de um único dia ($n = 1$), o critério reduz-se a $|AR_{i,t_0}| \geq 2\sigma_i$.

3.4.5 Ambiente e reprodutibilidade

O protótipo utiliza `pandas` e `numpy` (manipulação numérica), `networkx` e `python-louvain` (algoritmos de grafos) e `matplotlib` (visualizações). Todos os parâmetros experimentais (período, ativos, evento-foco, limiares, janelas e gap de carência) são centralizados em `main.py` e a semente aleatória é fixada, assegurando a reprodutibilidade. O código-fonte completo está disponível no repositório do projeto¹.

4 Resultados

Os experimentos foram conduzidos sobre dados reais de mercado obtidos via `yfinance`, considerando os **7 ativos** selecionados na Seção 3.2 ao longo de **825 pregões** (entre fevereiro de 2021 e março de 2024), que fornecem a camada estrutural de correlação e as janelas de estimação. A camada exógena concentra-se nos **3 eventos** mais agudos do conflito Rússia-Ucrânia. A Tabela 2 sumariza o conjunto de dados.

Tabela 2: Características do conjunto de dados.

Característica	Valor
Ativos	7
Eventos (conflito)	3
Pregões	825
Período	2021-02-01 a 2024-03-31

A análise organiza-se em torno das três visões fornecidas pelos algoritmos estrutura, agrupamento e propagação, encerrando-se com a validação estatística da camada exógena e o grafo direcionado de choques evento→ativo.

4.1 Estrutura do mercado (MST)

A Árvore Geradora Mínima (Figura 3) apresenta o esqueleto de correlação do mercado. O ativo central foi o **petróleo Brent** (BZ=F), com grau 4, atuando como principal eixo de transmissão de risco do conjunto, coerente com a matriz de correlação, em que o Brent exibe as ligações mais fortes (com a Petrobras, $\rho = 0,25$; com o trigo, 0,20; com o ouro, 0,18). A árvore apresentou comprimento total de 7,803 e 5 ativos periféricos (folhas). A Tabela 3 consolida essas métricas.

Tabela 3: Métricas da Árvore Geradora Mínima.

Métrica	Valor
Hub central	BZ=F
Grau do hub	4
Comprimento total	7,803
Ativos periféricos	5

¹<https://github.com/euarouca/Impacto-de-Eventos-Exogenos-sobre-o-Mercado-Financeiros>




Figura 3: Árvore Geradora Mínima do mercado. O tamanho do vértice é proporcional ao seu grau e a cor indica o setor do ativo.

4.2 Agrupamento por similaridade (Louvain)

A detecção de comunidades resultou em uma modularidade $Q \approx 0$, com a partição reduzindo-se a um núcleo conectado de 5 ativos (BZ=F, GC=F, ZW=F, LMT e PETR4.SA) e dois ativos isolados, CRWD (Cibersegurança) e RUB=X, que não exibem correlação diária relevante com os demais ($|\rho| \leq 0,05$ e $\leq 0,08$).

Tabela 4: Comunidades detectadas por Louvain ($Q \approx 0$).

Comunidade	Sector dominante	Tamanho
0	Safe Havens (núcleo correlacionado)	
1	Cibersegurança	
2	Índices e Câmbio	



Figura 4: Comunidades detectadas por Louvain. O núcleo de commodities/energia concentra as poucas correlações relevantes, enquanto Cibersegurança e Câmbio permanecem isolados.

A modularidade próxima de zero indica a **ausência de estrutura modular forte**, consequência direta da diversificação deliberada da carteira, cujas correlações máximas não ultrapassam 0,25 (Seção 3.2). Soma-se a isso uma limitação de projeto: como cada setor é representado por um único ativo, a

métrica de pureza fica restringida por construção.

4.3 Propagação do contágio (Dijkstra)

Tomando como evento-foco a invasão da Ucrânia (24/02/2022), o ponto de entrada do choque na rede foi o **câmbio do rublo** (RUB=X), o ativo de maior retorno anormal na janela. A partir dele, o algoritmo de Dijkstra computou os caminhos de menor resistência (Figura 5); a Tabela 5 lista os ativos mais próximos, ou seja, os primeiros alcançados pela cascata.

Tabela 5: Ordem de propagação do contágio a partir de RUB=X.

Posição	Ativo	Distância
1	GC=F	1,355
2	ZW=F	1,389
3	PETR4.SA	1,402
4	BZ=F	1,420
5	LMT	1,435




Figura 5: Caminhos de contágio a partir de RUB=X. As arestas em destaque formam a árvore de menor resistência; a cor do vértice indica a proximidade à origem do choque.

A ordem de propagação é coerente com a natureza do evento: a partir do rublo, o choque alcança primeiro os ativos de refúgio e commodities (ouro, trigo), seguidos do par Petrobras–Brent (eixo energético) e da defesa (LMT). A cibersegurança (CRWD), desconectada do núcleo, é a última alcançada.

4.4 Validação por Estudo de Eventos

Pelo Modelo de Retorno Médio Constante (média μ_i e volatilidade σ_i próprias, janela de estimação de 60 pregões separada por um gap de 10 dias), a Tabela 6 apresenta, para cada evento, o número de ativos com retorno anormal significativo ($|z| \geq 2$) e o CAR acumulado; a Figura 6 ilustra o contraste.

Os três eventos do conflito produziram impacto significativo e de magnitude semelhante ($CAR \approx 0,80$). O embargo ao petróleo russo atingiu o maior número de ativos (5), seguido da invasão e das sanções (4 cada). O resultado confirma a sensibilidade da carteira setorial (energia, defesa, agronegócio e câmbio) a choques geopolíticos.

Tabela 6: Ativos com retorno anormal significativo por evento.





Figura 6: Número de ativos com retorno anormal significativo por evento.

4.5 Camada exógena: grafo direcionado evento→ativo

A Figura 7 materializa a camada exógena E_{ex} (Eq. 3): um grafo **direcionado** em que cada aresta liga um evento ao ativo que sofreu choque significativo ($|z| \geq 2$). Foram identificadas **13 arestas de choque**; a cor distingue choques positivos (azul, $z > 0$) de negativos (vermelho, $z < 0$) e a espessura é proporcional ao peso $w = |\text{Goldstein}| \times |\text{CAR}|$ (Eq. 4). A Tabela 7 lista todas as arestas, ordenadas por peso.

Figura 7: Camada exógena: grafo direcionado evento→ativo. Aresta azul: retorno anormal positivo; vermelha: negativo; espessura proporcional a $w = |\text{Goldstein}| \times |\text{CAR}|$.

Ponderado pela Escala Goldstein, o canal mais intenso é o **trigo** ($ZW=F$) sob as sanções ($w = 3,84$), refletindo o peso de Rússia e Ucrânia na oferta global de grãos, seguido do **rublo** ($RUB=X$) na invasão ($w = 2,85$) e da reversão negativa do trigo no embargo ($w = 2,41$). Três ativos são atingidos por **todos** os eventos do conflito, $RUB=X$, LMT e $ZW=F$, confirmando-se como os vértices mais expostos ao risco geopolítico. Já a $PETR4.SA$ e o $GC=F$ não recebem aresta direta de choque na janela do conflito: a Petrobras responde de forma indireta, via correlação com o Brent (camada intra-mercado), enquanto o ouro só apresenta retorno anormal significativo fora do recorte.

Tabela 7: Arestas de choque evento→ativo ($|z| \geq 2$), com peso $w = |\text{Goldstein}| \times |\text{CAR}|$.

Evento (C_e)	Ativo	CAR	z	w
Invasão da Ucrânia (−10)	RUB=X	0,285	+17,05	2,85
	CRWD	0,224	+3,30	2,24
	LMT	0,157	+8,39	1,57
	ZW=F	0,137	+3,76	1,37
Sanções à Rússia (−9)	ZW=F	0,427	+11,29	3,84
	RUB=X	0,189	+11,37	1,70
	BZ=F	0,108	+2,27	0,98
	LMT	0,086	+4,11	0,77
Embargo ao petróleo (−9)	ZW=F	−0,267	−7,24	2,41
	RUB=X	0,202	+10,86	1,82
	CRWD	0,150	+2,17	1,35
	BZ=F	−0,106	−2,94	0,95
	LMT	−0,069	−3,09	0,62

5 Conclusões

Este trabalho propôs e implementou uma abordagem computacional baseada em **grafos temporais multiplex** para representar, integrar e analisar o impacto de eventos exógenos sobre o mercado financeiro, articulando o fluxo de notícias do GDELT com as cotações do yfinance. A separação do problema em duas camadas, a camada exógena direcionada (evento→ativo), filtrada por estudo de eventos com o Modelo de Retorno Médio Constante, e a camada intra-mercado não direcionada, baseada na correlação de Pearson mostrou-se eficaz para isolar simultaneamente o efeito de cada choque e a estrutura sistêmica entre os ativos. Sobre 7 ativos, um por segmento macroeconômico, e os 3 eventos mais agudos do conflito Rússia-Ucrânia, três algoritmos de Teoria dos Grafos (MST, Louvain e Dijkstra), somados à validação por retorno anormal, ofereceram visões complementares do mesmo sistema.

Os resultados evidenciaram que o **petróleo Brent** ($BZ=F$) ocupa a posição central da carteira: foi o **hub** da Árvore Geradora Mínima (grau 4) e exibiu as correlações mais fortes do conjunto, confirmando o eixo energético como principal canal de transmissão de risco. A detecção de comunidades retornou modularidade próxima de zero, revelando a **ausência de estrutura modular forte**: em vez de falha do método, trata-se de um achado coerente com a diversificação deliberada da carteira, em que apenas um núcleo de *commodities*/energia concentra movimento, enquanto cibersegurança ($CRWD$) e câmbio ($RUB=X$) atuam como diversificadores. Já a propagação modelada pelo Dijkstra, tendo o rublo ($RUB=X$) como ponto de entrada do choque da invasão, alcançou em cascata os ativos de refúgio e *commodities*, o par Petrobras–Brent e a defesa, traçando um caminho de contágio economicamente plausível.

A camada exógena — com 13 arestas direcionadas significativas ($|z| \geq 2$), ponderadas por $w = |\text{Goldstein}| \times |\text{CAR}|$ — materializou a hipótese central da modelagem. Os canais mais intensos foram o trigo ($ZW=F$) sob as sanções e o rublo ($RUB=X$) ao longo de todo o conflito; três ativos, $RUB=X$, LMT e $ZW=F$, foram atingidos por todos os eventos, confirmando-se como os vértices mais expostos ao risco geopolítico, ao passo que a Petrobras respondeu de forma indireta, via correlação com o Brent, e não por aresta direta de choque. Esse resul-

tado ilustra exatamente o tipo de relação choque direto *versus* contágio estrutural, que análises isoladas de séries temporais dificilmente tornariam explícita.

Os achados devem ser lidos à luz de algumas **limitações**. A correlação de Pearson captura apenas dependências lineares, e os caminhos do Dijkstra indicam proximidade e associação estrutural, não causalidade. O critério $|z_{AR}| \geq 2$ pressupõe normalidade aproximada dos retornos. O recorte de 7 ativos é deliberadamente reduzido: limita a representatividade estatística, já que a métrica de pureza fica restringida por construção.

Em síntese, a modelagem multiplex proposta constitui uma ferramenta para mapear como choques exógenos se propagam pelo mercado, fornecendo subsídios concretos para a análise de risco e o aprimoramento de portfólios frente a eventos adversos.

Divisão de tarefas

Chaque! Escrita da Introdução (1), contextualização do trabalho, organização das reuniões do grupo, construção dos slides da apresentação e revisão geral do relatório.

Eduardo: Busca de referência, escolha de metodologia, revisão teórica

Lucas Arouca: Implementação dos algoritmos, análise e conclusão sobre os dados obtidos. Escrita das seções de Desenvolvimento (3.4), Resultados (4) e Conclusão (5).

Luiz Gustavo: Detalhamento do problema (3.1), características do dataset (3.2), responsável pela modelagem (3.3) e contribuição no referencial teórico.

Thiago: Definição da arquitetura geral do projeto, sugestão de métodos de análise, contribuição para fontes/dados e modelagem

Referências

- Billio, M., Getmansky, M., Lo, A. W., & Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- Camargos, M. A. d. & Barbosa, F. V. (2003). Estudos de evento: teoria e operacionalização. *Caderno de Pesquisas em Administração*, 10(3), 1–20.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- French, K. R. (1980). Stock returns and the weekend effect. *Journal of Financial Economics*, 8(1), 55–69.
- Goldstein, J. S. (1992). A conflict-cooperation scale for WEIS events data. *Journal of Conflict Resolution*, 36(2), 369–385.
- Holme, P. & Saramäki, J. (2012). Temporal networks. *Physics Reports*, 519(3), 97–125.
- Kivelä, M., Arenas, A., Barthelemy, M., Gleeson, J. P., Moreno, Y., & Porter, M. A. (2014). Multilayer networks. *Journal of Complex Networks*, 2(3), 203–271.

Leetaru, K. & Schrodt, P. A. (2013). Gdelt: Global data on events, location, and tone, 1979–2012. Em *ISA Annual Convention*.

MacKinlay, A. C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, 35(1), 13–39.

Mantegna, R. N. (1999). Hierarchical structure in financial markets. *The European Physical Journal B*, 11(1), 193–197.

Mantegna, R. N. & Stanley, H. E. (2000). *An Introduction to Econophysics: Correlations and Complexity in Finance*. Cambridge: Cambridge University Press.

Pearson, K. (1895). Notes on regression and inheritance in the case of two parents. *Proceedings of the Royal Society of London*, 58, 240–242.

Schrodt, P. A. & Gerner, D. J. (2001). *Conflict and Mediation Event Observations (CAMEO) Codebook*. Technical report, Penn State University.

Tumminello, M., Lillo, F., & Mantegna, R. N. (2010). Correlation, hierarchies, and networks in financial markets. *Journal of Economic Behavior & Organization*, 75(1), 40–58.

Zaheer, K., Aslam, F., Mohmand, Y. T., & Ferreira, P. (2024). On the dynamic changes in the global stock markets' network during the russia-ukraine war. *Economies*, 12(2), 41.

